INFERENCIA ESTADÍSTICA

MICD:
Probabilidad y Estadística

- Propiedades.
- Máxima Verosimilitud

PROBLEMA DE ESTIMACIÓN

- El proceso de estimar θ a partir de $\mathfrak{D}$ se llama ajuste del modelo o entrenamiento.
- La mayoría de los métodos para producir tales estimaciones se reducen al siguiente problema de estimación:

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta}}{\operatorname{argmin}}\, \mathcal{L}(\boldsymbol{\theta})$$

- En este caso $\mathcal{L}$ se denomina función de perdida o función objetivo.
- El proceso de cuantificar la incertidumbre sobre una cantidad desconocida estimada a parir de una muestra se denomina inferencia.

INFERENCIA ESTADÍSTICA

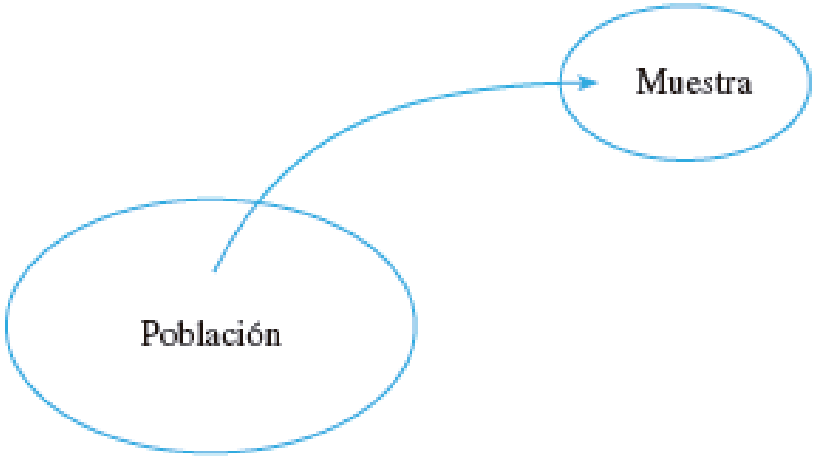

Definición La **estadística inferencial** está formada por procedimientos empleados para hacer inferencias acerca de características poblacionales, a partir de información contenida en una muestra sacada de esta población.

EJEMPLOS DE ESTADÍSTICOS

Estadístico	Definición matemática	Procedimiento en Python
Media muestral $\bar{X}$	$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$	`np.mean(datos)`
Varianza muestral S^2	$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$	`np.var(datos, ddof=1)`
Desviación estándar S	$S = \sqrt{S^2}$	`np.std(datos, ddof=1)`
Mediana muestral $\tilde{X}$	Valor central de los datos ordenados	`np.median(datos)`
Rango R	$R = X_{(n)} - X_{(1)}$	`np.max(datos) - np.min(datos)`
Cuartiles Q_k	$Q_k = X_{\left(\frac{k(n+1)}{4}\right)}\ (k = 1, 2, 3)$	`np.percentile(datos, [25, 50, 75])`

Coeficiente de asimetría g_1	$g_1 = \frac{\frac{1}{n}\sum(X_i - \bar{X})^3}{S^3}$	`scipy.stats.skew(datos, bias=False)`
Curtosis muestral g_2	$g_2 = \frac{\frac{1}{n}\sum(X_i - \bar{X})^4}{S^4} - 3$	`scipy.stats.kurtosis(datos, fisher=True, bias=False)`
Estadístico mínimo	$X_{(1)} = \min\{X_1, \ldots, X_n\}$	`np.min(datos)`
Estadístico máximo	$X_{(n)} = \max\{X_1, \ldots, X_n\}$	`np.max(datos)`

DISTRIBUCIONES MUESTRALES

Sea $Y_1, Y_2, \ldots, Y_n$ una muestra aleatoria de tamaño n de una distribución normal con media μ y varianza σ^2. Entonces

$$\overline{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i$$

está distribuida normalmente con media $\mu_{\overline{Y}} = \mu$ y varianza $\sigma^2_{\overline{Y}} = \sigma^2/n$.

EJEMPLO

Una máquina embotelladora puede ser regulada para que descargue un promedio de μ onzas por botella. Se ha observado que la cantidad de líquido dosificado por la máquina está distribuida normalmente con $\sigma = 1.0$ onza. Una muestra de $n = 9$ botellas se selecciona aleatoriamente de la producción de la máquina en un día determinado (todas embotelladas con el mismo ajuste de la máquina) y las onzas de contenido líquido se miden para cada una. Determine la probabilidad de que la media muestral se encuentre a no más de .3 onza de la verdadera media μ para el ajuste seleccionado de la máquina.

¿Cuantas observaciones deben estar incluidas en la muestra si deseamos que $\bar{Y}$ se encuentre a no mas de .3 onza de μ con probabilidad de .95?

Sea $Y_1, Y_2, \ldots, Y_n$ una muestra aleatoria de una distribución normal con media μ y varianza σ^2. Entonces

$$\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(Y_i - \overline{Y})^2$$

tiene una distribución χ^2 con $(n-1)$ gl. También, $\overline{Y}$ y S^2 son variables aleatorias independientes.

EJEMPLO

En el Ejemplo, se supone que las onzas de líquido que vierte la máquina embotelladora tienen una distribución normal con $\sigma^2 = 1$. Suponga que planeamos seleccionar una muestra aleatoria de diez botellas y medir la cantidad de líquido en cada una. Si estas diez observaciones se usan para calcular S^2, podría ser útil especificar un intervalo de valores que incluirán S^2 con una probabilidad alta. Encuentre números b_1 y b_2 tales que

$$P(b_1 \leq S^2 \leq b_2) = .90.$$

OTROS ESTADÍSTICOS

- Comentar sobre T y F.

TAREA

El rendimiento logarítmico diario $Y_t$de una acción se modela como normal con media desconocida μ y varianza σ^2 .Se eligen 6 días al azar y se observan $Y_1, \dots, Y_6$. ¿cuál es la probabilidad aproximada de que la media muestral $\bar{R}$esté a menos de $2S/\sqrt{6}$ de la media verdadera μ?

Un hospital compara la precisión de dos métodos para medir troponina (Método A vs. Método B). Se hacen 6 mediciones repetidas con A y 10 con B sobre el mismo material de control (condiciones idénticas). Si ambos métodos fueran igual de precisos, las lecturas serían normales con la misma varianza poblacional σ^2.Sea S_A^2y S_B^2 la varianza muestral de A y B, respectivamente. Se pide el número $b$tal que

$$P\left(\frac{S_A^2}{S_B^2} \leq b\right) = 0.95.$$

ESTIMACIÓN

- $X \sim f_\theta$
- $X_1, X_2, \dots, X_n \sim f_\theta$
- $\hat{\theta} = g(X_1, X_2, \dots, X_n)$

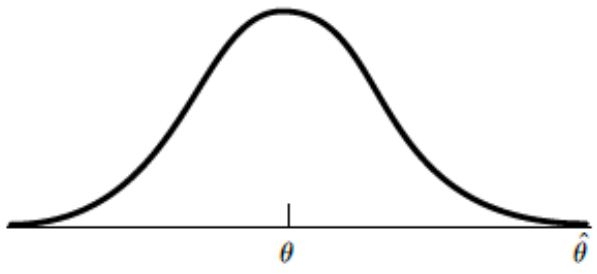

ERROR CUADRÁTICO MEDIO

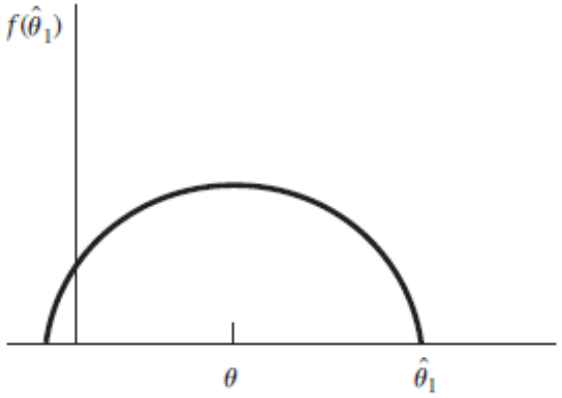

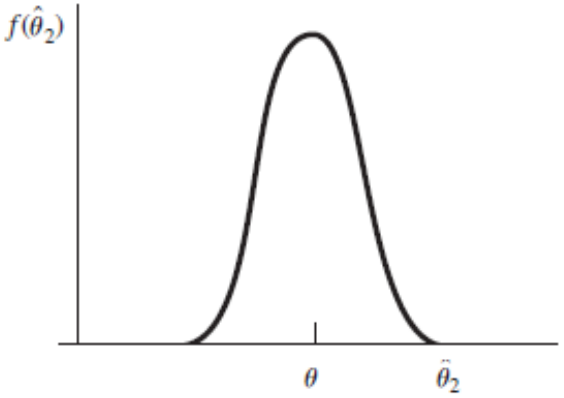

$$\mathrm{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2].$$

$$\mathrm{MSE}(\hat{\theta}) = V(\hat{\theta}) + [B(\hat{\theta})]^2.$$

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

TAREA

Suponga que Y_1, Y_2, Y_3 denotan una muestra aleatoria de una distribución exponencial con función de densidad

$$f(y) = \begin{cases} \left(\dfrac{1}{\theta}\right) e^{-y/\theta}, & y > 0, \\ 0, & \text{en cualquier otro punto.} \end{cases}$$

Considere los siguientes cinco estimadores de θ:

$$\hat{\theta}_1 = Y_1, \qquad \hat{\theta}_2 = \frac{Y_1 + Y_2}{2}, \qquad \hat{\theta}_3 = \frac{Y_1 + 2Y_2}{3}, \qquad \hat{\theta}_4 = \text{mín}(Y_1, Y_2, Y_3), \qquad \hat{\theta}_5 = \overline{Y}.$$

a ¿Cuáles de estos estimadores son insesgados?

b Entre los estimadores insesgados, ¿cuál tiene la varianza más pequeña?

Dados dos estimadores insesgados $\hat{\theta}_1$ y $\hat{\theta}_2$ de un parámetro θ, con varianzas $V(\hat{\theta}_1)$ y $V(\hat{\theta}_2)$, respectivamente, entonces la *eficiencia* de $\hat{\theta}_1$ con respecto a $\hat{\theta}_2$, denotada $\text{eff}(\hat{\theta}_1, \hat{\theta}_2)$, se define como la razón

$$\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = \frac{V(\hat{\theta}_2)}{V(\hat{\theta}_1)}.$$

Sea $Y_1, Y_2, \ldots, Y_n$ una muestra aleatoria de una distribución uniforme en el intervalo $(0, \theta)$. Dos estimadores insesgados para θ son

$$\hat{\theta}_1 = 2\overline{Y} \text{ y } \hat{\theta}_2 = \left(\frac{n+1}{n}\right) Y_{(n)},$$

cuando $Y_{(n)} = \text{máx}\,(Y_1, Y_2, \ldots, Y_n)$. Encuentre la eficiencia de $\hat{\theta}_1$ con respecto a $\hat{\theta}_2$.

TAREA

Suponga que $Y_1, Y_2, \ldots, Y_n$ es una muestra aleatoria de una distribución normal con media μ y varianza σ^2. Dos estimadores insesgados de σ^2 son

$$\hat{\sigma}_1^2 = S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(Y_i - \overline{Y})^2 \quad \text{y} \quad \hat{\sigma}_2^2 = \frac{1}{2}(Y_1 - Y_2)^2.$$

Encuentre la eficiencia de $\hat{\sigma}_1^2$ con respecto a $\hat{\sigma}_2^2$.

CONSISTENCIA

El *error de estimación* ε es la distancia entre un estimador y su parámetro objetivo. Esto es, $\varepsilon = |\hat{\theta} - \theta|$.

Se dice que el estimador $\hat{\theta}_n$ es un *estimador consistente* de θ si, para cualquier número positivo ε,

$$\lim_{n \to \infty} P(|\hat{\theta}_n - \theta| \leq \varepsilon) = 1$$

o bien, de forma equivalente,

$$\lim_{n \to \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0.$$

TEOREMA

Un estimador insesgado $\hat{\theta}_n$ para θ es un estimador consistente de θ si

$$\lim_{n \to \infty} V(\hat{\theta}_n) = 0.$$

Sea $Y_1, Y_2, \ldots, Y_n$ una muestra aleatoria de la función de densidad de probabilidad

$$f(y) = \begin{cases} \theta y^{\theta - 1}, & 0 < y < 1, \\ 0, & \text{en cualquier otro punto,} \end{cases}$$

TEOREMA

Suponga que $\hat{\theta}_n$ converge en probabilidad en θ y que $\hat{\theta}'_n$ converge en probabilidad en θ'.

a $\hat{\theta}_n + \hat{\theta}'_n$ converge en probabilidad en $\theta + \theta'$.

b $\hat{\theta}_n \times \hat{\theta}'_n$ converge en probabilidad en $\theta \times \theta'$.

c Si $\theta' \neq 0$, $\hat{\theta}_n / \hat{\theta}'_n$ converge en probabilidad en θ / θ'.

d Si $g(\cdot)$ es una función de valor real que es continua en θ, entonces $g(\hat{\theta}_n)$ converge en probabilidad en $g(\theta)$.

TAREA

Un experimentador desea comparar los números de bacterias de tipos A y B en muestras de agua. Se toma un total de n muestras de agua independientes y se hacen las cuentas para cada muestra. Sea X_i el número de bacterias tipo A y Y_i el número de bacterias tipo B para la muestra i. Suponga que los dos tipos de bacterias están distribuidos escasamente dentro de una muestra de agua, de modo que X_1, $X_2, \ldots, X_n$ y $Y_1, Y_2, \ldots, Y_n$ se pueden considerar muestras aleatorias independientes de distribuciones de Poisson con medias λ_1 y λ_2, respectivamente. Sugiera un estimador de $\lambda_1/(\lambda_1 + \lambda_2)$. ¿Qué propiedades tiene el estimador propuesto por usted?

SUFICIENCIA

- Es un estimador que concentra toda la información de la muestra acerca del parámetro de interés. Resume la información de la muestra, en el siguiente sentido:

Sea $Y_1, Y_2, \ldots, Y_n$ una muestra aleatoria de una distribución de probabilidad con parámetro desconocido θ. Entonces se dice que el estadístico $U = g(Y_1, Y_2, \ldots, Y_n)$ es *suficiente* para θ si la distribución condicional de $Y_1, Y_2, \ldots, Y_n$, dada U, no depende de θ.

EJEMPLO

- Supongamos una población Bernoulli(p), donde p es el parámetro a estimar.
- Propongamos el estimador

$$Y = \sum_{i}^{n} Y_i \, .$$

FUNCIÓN DE VEROSIMILITUD

- Sea X una población y $(X_1, X_2, \dots, X_n)$ una muestra aleatoria. La función de verosimilitud se define como:

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^{n} f(x_i; \theta),$$

- Vista como función de θ, dado el conjunto de datos observados.

TEOREMA

Sea U un estadístico basado en la muestra aleatoria $Y_1, Y_2, \ldots, Y_n$. Entonces U es un *estadístico suficiente* para la estimación de un parámetro θ si y sólo si la verosimilitud $L(\theta) = L(y_1, y_2, \ldots, y_n \mid \theta)$ se puede factorizar en dos funciones no negativas,

$$L(y_1, y_2, \ldots, y_n \mid \theta) = g(u, \theta) \times h(y_1, y_2, \ldots, y_n$$

donde $g(u, \theta)$ es una función sólo de u y θ y $h(y_1, y_2, \ldots, y_n)$ no es una función de θ.

EJEMPLO

- Distribución Normal

TAREA

La función de densidad de Rayleigh está dada por

$$f(y) = \begin{cases} \left(\dfrac{2y}{\theta}\right) e^{-y^2/\theta}, & y > 0, \\ 0, & \text{en cualquier otro punto.} \end{cases}$$

a) Investigar el uso de la distribución en áreas aplicadas.
b) Calcular la distribución de Y^2.
c) ¿$\widehat{W}_n = \frac{1}{n}\sum_{i=1}^{n} Y_i^2$ es un estimador consistente para θ?
d) ¿$\hat{S}_n = \sum_{i=1}^{n} Y_i^2$ es suficiente para θ?

TEOREMA (ESTIMADOR INSESGADO DE VARIANZA MÍNIMA)

El Teorema de Rao–Blackwell Sea $\hat{\theta}$ un estimador insesgado para θ tal que $V(\hat{\theta}) < \infty$. Si U es un estadístico suficiente para θ, definamos $\hat{\theta}^* = E(\hat{\theta} \mid U)$. Entonces, para toda θ,

$$E\left(\hat{\theta}^*\right) = \theta \quad \text{y} \quad V\left(\hat{\theta}^*\right) \leq V(\hat{\theta}).$$

FUNCIÓN DE VEROSIMILITUD

- Sea X una población y $(X_1, X_2, \dots, X_n)$ una muestra aleatoria. La función de verosimilitud se define como:

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^{n} f(x_i; \theta),$$

- Vista como función de θ, dado el conjunto de datos observados.
- De este modo, buscamos:

$$\hat{\theta}_{MV} = \arg\max_{\theta \in \Theta} L(\theta; x_1, x_2, \dots, x_n),$$

EJEMPLO DISCRETO

EJEMPLO: NORMAL

- Tarea: Normal Multivariada.

ESTIMACIÓN RECURSIVA (ONLINE ESTIMATION)

- Si todo el conjunto de datos $\mathcal{D}$ está disponible antes de que comience el entrenamiento, decimos que estamos haciendo **aprendizaje por lotes** (*batch learning*).
- Sin embargo, en algunos casos, el conjunto de datos llega de manera secuencial, así que $\mathcal{D} = \{y_1, y_2, \ldots\}$. En este caso, queremos realizar **aprendizaje en línea** (*online learning*).

$$\theta_t = f(\hat{\theta}_{t-1}, y_t)$$

EJEMPLO: MEDIA-GAUSSIANA

$$\hat{\boldsymbol{\mu}}_t = \frac{1}{t}\sum_{n=1}^{t} \boldsymbol{y}_n$$

$$\begin{aligned}\hat{\boldsymbol{\mu}}_t &= \frac{1}{t}\sum_{n=1}^{t} \boldsymbol{y}_n = \frac{1}{t}\left((t-1)\hat{\boldsymbol{\mu}}_{t-1} + \boldsymbol{y}_t\right) \\ &= \hat{\boldsymbol{\mu}}_{t-1} + \frac{1}{t}(\boldsymbol{y}_t - \hat{\boldsymbol{\mu}}_{t-1})\end{aligned}$$

MEDIA MÓVIL PONDERADA EXPONENCIALMENTE

$$\hat{\mu}_t = \beta \mu_{t-1} + (1 - \beta) y_t$$

La contribución de un punto de datos k pasos en el pasado se pondera por $\beta^k (1 - \beta)$.

MÉTODOS GRADIENTE

- Procedimientos iterativos para determinar el valor óptimo (mínimo) de una función objetivo f. En específico supongamo que:

$$f(\theta) = \frac{1}{N}\sum_{i=1}^{N} f_i(\theta),$$

- Gradiente por Descenso Clásico (BGD):

$$\theta_{k+1} = \theta_k - \eta\frac{1}{N}\sum_{i=1}^{N}\nabla f_i(\theta_k)$$

- Gradiente por Descenso Estocástico (SGD):

$$\theta_{k+1} = \theta_k - \eta\nabla f_{i_k}(\theta_k), \quad i_k \sim \{1, \ldots, N\}$$

- Gradiente por Descenso mini-lotes (M-BSGD)

$$\theta_{k+1} = \theta_k - \eta\frac{1}{B}\sum_{i\in\mathcal{B}_k}\nabla f_i(\theta_k), \quad |\mathcal{B}_k| = B$$

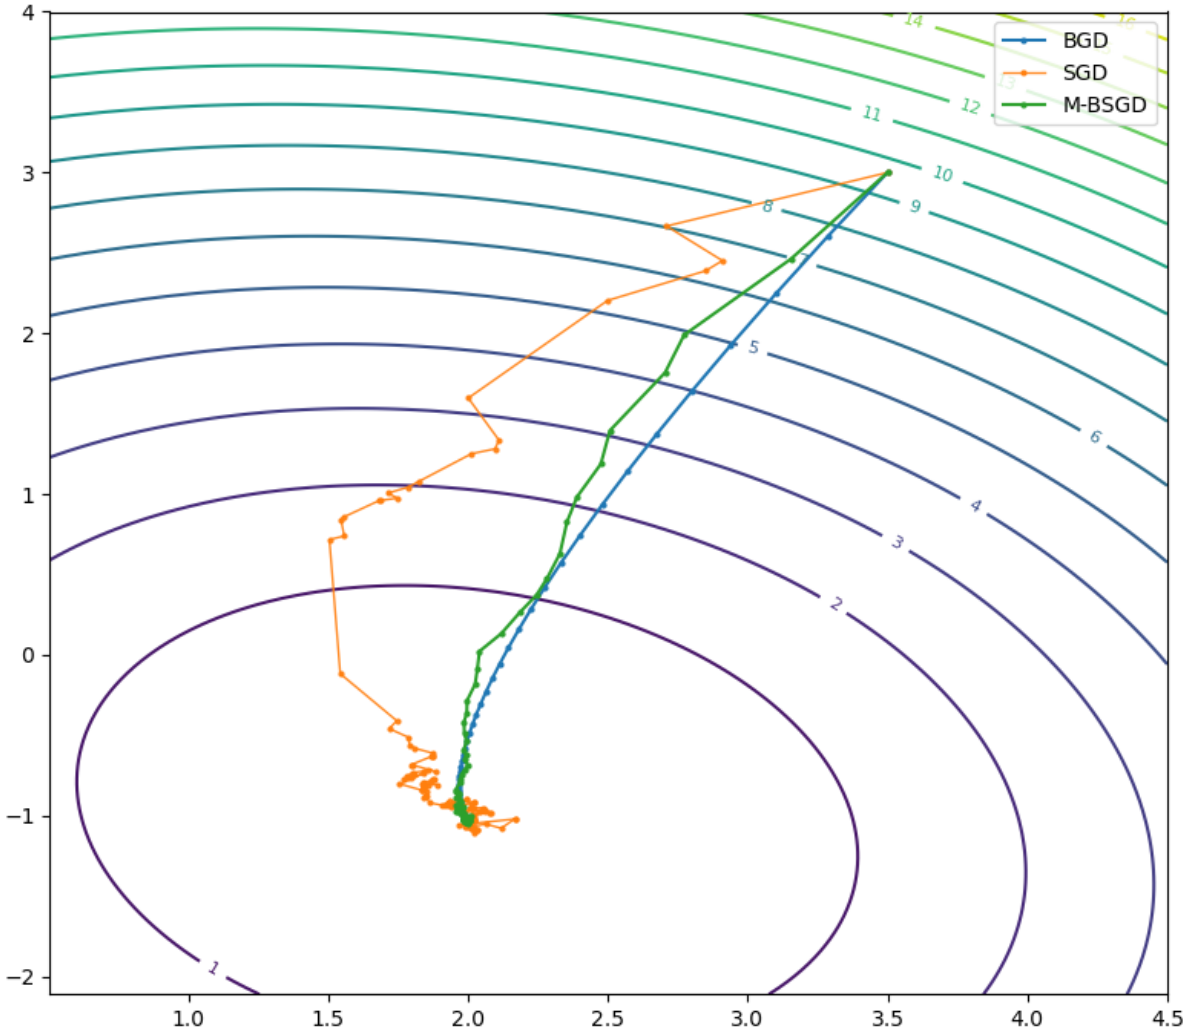
BGD
SGD
M-BSGD
4
3
2
1
0
−1
−2
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5
1
2
3
4
5
6
7
8
9
10
11
12
13
14

AIC+BIC

- Criterios para comparar models estadísticos, considerando: Bondad de ajuste y Complejidad en el modelo.
- AIC=-2*ln(L)+2*k
- BIC=-2*ln(L)+k*ln(n)
- BIC asigna una penalización mayor a la complejidad del modelo.
- Sugerencia: Usar AIC en caso de requerir presición predictiva. Usar BIC si la prioridad es la parsimonia.

PASOS PARA AJUSTE DE DITRIBUCIONES

1. Exploración de Datos.
2. Selección de Distribuciones Candidatas.
3. Estimación de Parámetros.
4. Evaluación y Selección.