INFERENCIA ESTADÍSTICA

MICD:
Probabilidad y Estadística

- Intervalos de Confianza.
- Pruebas de Hipótesis

SISTEMA DE DISTRIBUCIONES PEARSON

Figure 1. Seven types of Pearsonian distributions for different values of k

Types	Density function	Range of r.v.	Parameters
Type – I	$f(y) = y_0\left(1+\frac{x}{a_1}\right)^{m_1}\left(1-\frac{x}{a_2}\right)^{m_2}$	$-a_1 < x < a_2$	$m_1, m_2 > 0$
Type – II	$f(y) = y_0\left(1-\frac{x^2}{a^2}\right)^{m}$	$-a < x < a$	$m > -1$
Type – III	$f(y) = y_0\left(1+\frac{x}{a}\right)^{\mu a} e^{-\mu x}$	$-a < x < \infty$	$\mu, a > -1$
Type – IV	$f(y) = y_0\left(1+\frac{x^2}{a^2}\right)^{-m} e^{-\mu \tan^{-1}(x/a)}$	$-\infty < x < \infty$	$a, \mu, m > 0$
Type – V	$f(y) = y_0 x^{-p} e^{-(a/x)}$	$0 < x < \infty$	$a > 0,\ p > 1$
Type – VI	$f(y) = y_0 x^{-p}(x-a)^{q}$	$a < x < \infty$	$q > -1,\ p < 1$
Type – VII	$f(y) = y_0\left(1+\frac{x^2}{a^2}\right)^{-m}$	$-\infty < x < \infty$	$m > \frac{1}{2}$
Type-VIII	$f(y) = y_0\left(1+\frac{x}{a}\right)^{-m}$	$-a < x \le 0$	$m > 1$
Type – IX	$f(y) = y_0\left(1+\frac{x}{a}\right)^{m}$	$-a < x \le 0$	$m > -1$
Type – X	$f(y) = y_0 e^{-(x/\sigma)}$	$0 \le x < \infty$	$\sigma > 0$
Type – XI	$f(y) = y_0 x^{-m}$	$b \le x < \infty$	$m > 1$
Type – XII	$f(y) = y_0\left(\frac{g+x}{g-x}\right)^{m}$	$-g \le x \le g$	$\lvert m\rvert < 1$

Table 1. Pearsonian Family of Distribution density functions

$$K = \frac{\gamma_1^2(\gamma_2+6)^2}{4(4\gamma_2 - 3\gamma_1^2 + 12)(2\gamma_2 - 3\gamma_1^2)},$$

- γ_1 = coeficiente de asimetría de Pearson.
- γ_2 = coeficiente de curtosis de Pearson (exceso de curtosis).

$K < 0$: distribuciones de tipo I (similares a beta, con soporte acotado).

$K = 0$: distribuciones de tipo II (beta simétrica).

$0 < K < 1$: distribuciones de tipo IV (asimétricas, con colas pesadas).

$K = 1$: distribución normal.

$K > 1$: distribuciones de tipo VI (similares a F, colas pesadas).

REFERENCIAS

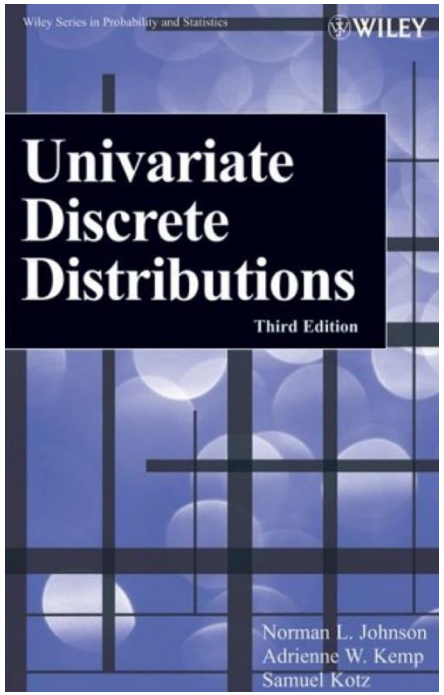

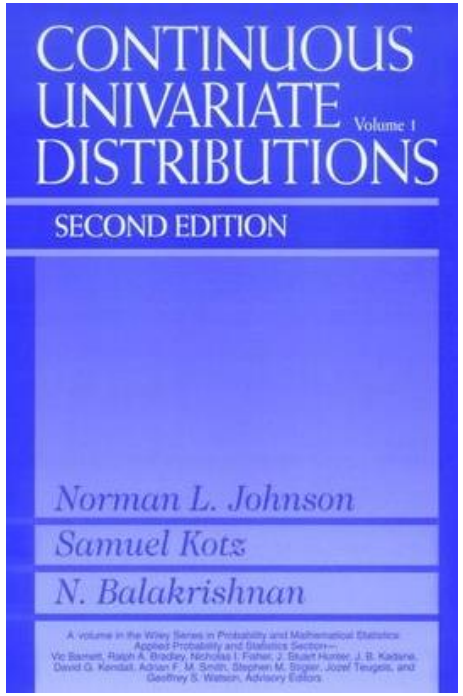

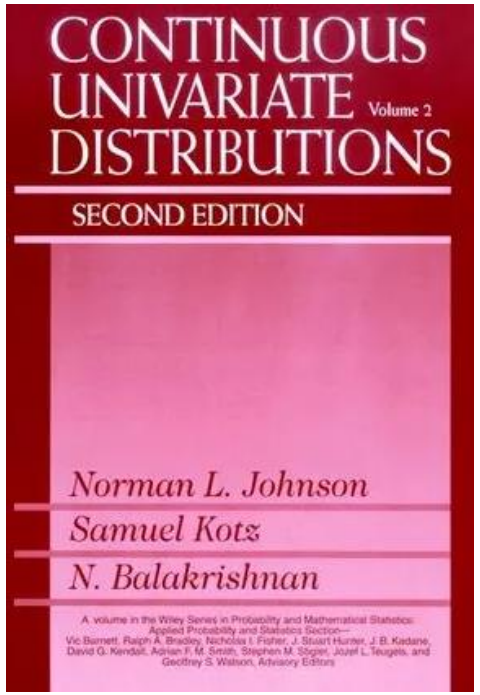

MÉTODO DE MOMENTOS

- Momentos Poblacionales

$$\mu'_k = \mathbb{E}[X^k], \quad k = 1, 2, \ldots$$

- Momentos muestrales

$$m'_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k, \quad k = 1, 2, \ldots$$

- Método

$$m'_k = \mu'_k(\theta), \quad k = 1, \ldots, p$$

EJEMPLO:GAMMA

$$\hat{\alpha} = \frac{\overline{Y}^2}{\left(\sum Y_i^2 / n\right) - \overline{Y}^2} = \frac{n\overline{Y}^2}{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}.$$

$$\hat{\beta} = \frac{\overline{Y}}{\hat{\alpha}} = \frac{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}{n\overline{Y}}.$$

TAREA:

Sea $Y_1, Y_2, \ldots, Y_n$ una muestra aleatoria de la función de densidad de probabilidad dada por

$$f(y \mid \theta) = \begin{cases} \left(\dfrac{2}{\theta^2}\right)(\theta - y), & 0 \leq y \leq \theta, \\ 0, & \text{en cualquier otro punto.} \end{cases}$$

a Encuentre un estimador para θ usando el método de momentos.

b ¿Este estimador es un estadístico suficiente para θ?

ESTIMADOR POR INTERVALOS

- Un *estimador de intervalo* es una regla que especifica el método para usar las mediciones muestrales en el calculo de dos números que forman los puntos extremos del intervalo.
- El intervalo resultante tiene dos propiedades:

  a) contiene el parámetro objetivo.

  b) su amplitud será relativamente pequeña.
- Los puntos extremos superior e inferior de un intervalo de confianza se denominan *limites de confianza superior* e *inferior*, respectivamente.
- La probabilidad de que un intervalo de confianza (aleatorio) incluya al parámetro se llama *coeficiente de confianza.*

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U\right) = 1 - \alpha,$$

ESTIMADOR POR INTERVALOS

- *intervalos de confianza unilaterales*

$$P\left(\hat{\theta}_L \leq \theta\right) = 1 - \alpha. \qquad P(\theta \leq \hat{\theta}_U) = 1 - \alpha.$$

- *PUNTUAL vs INTERVALOS*

"La proporción de clientes satisfechos es 82%".

"Con 95% de confianza, la proporción de clientes satisfechos está entre 79% y 85%".

MÉTODO DEL PIVOTE

Un procedimiento muy útil para construir intervalos de confianza es el *método del pivote*. Este consiste en encontrar una cantidad (llamada *pivote*) que cumpla con las siguientes características:

1. Sea una función de la muestra y del parámetro desconocido θ, de manera que θsea la única incógnita.
2. Su distribución de probabilidad no dependa del parámetro θ.

EJEMPLO

Suponga que obtenemos una sola observación Y de una distribución exponencial con media θ. Use Y para construir un intervalo de confianza para θ con un coeficiente de confianza de 0.90.

$$f(y) = \begin{cases} \left(\frac{1}{\theta}\right) e^{-y/\theta}, & y \geq 0, \\ 0, & \text{en cualquier otro punto.} \end{cases}$$

TAREA

$$f_Y(y) = \begin{cases} \dfrac{2(\theta - y)}{\theta^2}, & 0 < y < \theta, \\ 0, & \text{en cualquier otro punto.} \end{cases}$$

IC PARA LA MEDIA EN UNA POBLACIÓN NORMAL/APROXIMADAMENTE NORMAL

Sea X una v.a. normal con media poblacional μ desconocida y desviación poblacional σ conocida. Sea $X_1, \ldots, X_n$ una muestra aleatoria de X, con media muestral $\bar{X}$. Determinar un intervalo de confianza bilateral para μ con nivel de confianza $1-\alpha$.

De acuerdo con la definición buscamos un intervalo $[\hat{\theta}_L, \hat{\theta}_U]$ tal que

$$\mathbb{P}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha,$$

INTERVALO DE CONFIANZA PARA LA VARIANZA

Un intervalo de confianza $100(1-\alpha)\%$ para σ^2

$$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{1-(\alpha/2)}}\right)$$

TAREA

- Encontrar intervalos de confianza para diferencia de medias y cociente de varianzas.

INTERVALOS DE CONFIANZA

Probabilidad y Estadística

CONCEPTOS BÁSICOS

- OBSERVAR → FORMULAR/CONJETURAR → COMPROBAR
- Una afirmación se comprueba demostrando que no hay evidencia que sustente la afirmación opuesta.

Los elementos de una prueba estadística

1. Hipótesis nula, H_0
2. Hipótesis alternativa, H_a
3. Estadístico de prueba
4. Región de rechazo

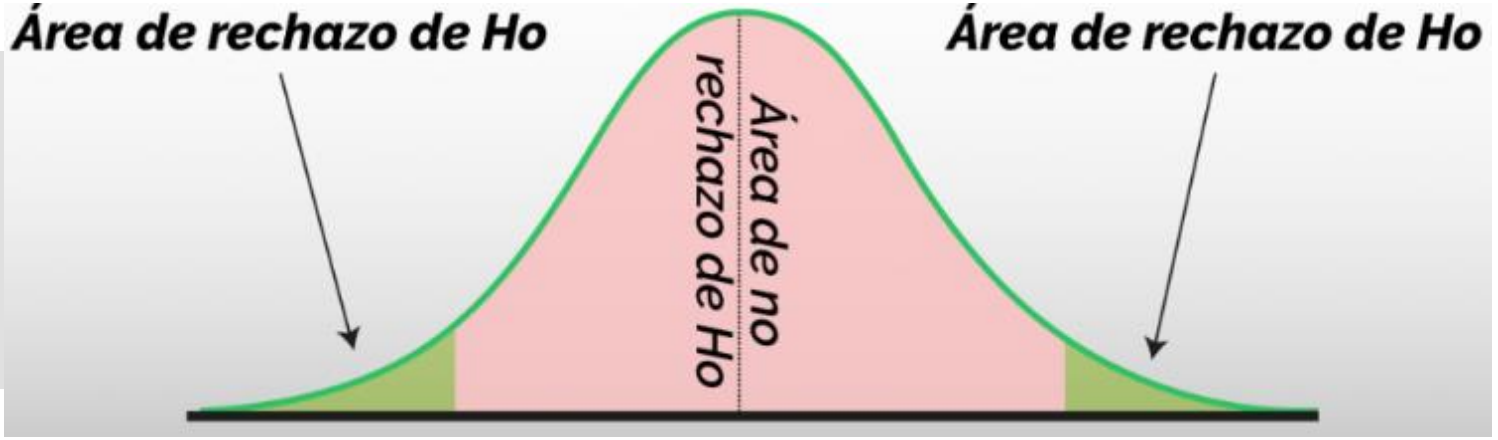

HIPÓTESIS

- Pasos a seguir:

1. Definir la pregunta estadística.
2. Identificar el parámetro poblacional relevante.
3. Traducir esa pregunta en una hipótesis nula y una alternativa.

- **Hipótesis nula (H0)**: Es la afirmación que se somete a prueba y representa el estado actual o una situación de no efecto. Generalmente, se asume verdadera hasta que haya evidencia en su contra. Esta hipótesis se opone a la hipótesis del investigador.
- **Hipótesis alternativa (Ha)**: Es la afirmación que queremos demostrar y que representa una diferencia, efecto o cambio en la población.

Tipo de hipótesis	Formulación	Uso
Bilateral	$H_1: \theta \neq \theta_0$	Si interesa detectar cualquier cambio.
Unilateral derecha	$H_1: \theta > \theta_0$	Si se busca mejora o aumento.
Unilateral izquierda	$H_1: \theta < \theta_0$	Si se busca reducción o disminución.

EJEMPLOS

- Se lleva a cabo un ensayo médico para comprobar si un nuevo medicamento reduce el colesterol en un 25 %.

  - H_0: The drug reduces cholesterol by 25%. $p = 0.25$
  - H_a: The drug does not reduce cholesterol by 25%. $p \neq 0.25$

- Queremos comprobar si los estudiantes universitarios tardan, en promedio, menos de cinco años en graduarse de la universidad.

  - $H_0 : \mu \geq 5$
  - $H_a : \mu < 5$

- En un examen de manejo estatal, aproximadamente el 40 % aprueba el examen en el primer intento. Queremos comprobar si más del 40 % aprueba en el primer intento.

a. $H_0 : p = 0.40$
b. $H_a : p > 0.40$

TIPOS DE ERRORES

Se comete un *error tipo I* si H_0 es rechazada cuando H_0 es verdadera. La *probabilidad de un error tipo I* está denotada por α. El valor de α se denomina *nivel* de la prueba.

Se comete un *error tipo II* si H_0 es aceptada cuando H_a es verdadera. La *probabilidad de un error tipo II* está denotada por β.

Decisión	H_0 **verdadera**	H_0 **falsa**
No rechazar H_0	CORRECTO	ERROR TIPO II
Rechazar H_0	ERROR TIPO 1	CORRECTO

$P(\text{no rechazar } H_0 \mid H_0 \text{ es falsa}) = \beta$

$P(\text{rechazar } H_0 \mid H_0 \text{ es cierta}) = \alpha$

Contexto	Error tipo I costoso	Error tipo II costoso
Control de calidad	Rechazar un lote bueno	Aceptar un lote defectuoso
Diagnóstico médico	Declarar enfermo a alguien sano	No detectar una enfermedad

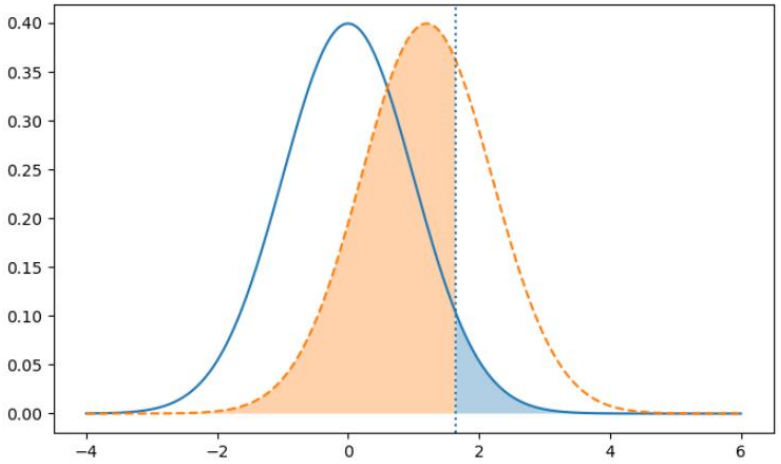

EJEMPLO

- En una fábrica, los paquetes de café se producen con un peso medio ajustado (más propiamente habría que decir: masa) de 500 gramos. Se asume que el peso de los paquetes de café sigue una distribución $N(500, 50)$. En grandes contenedores se almacenan los paquetes de café. Por un error en el ajuste del peso, un cierto número de contenedores (no se sabe cuáles) se llenó con paquetes de café cuyo peso sigue una distribución $N(490, 50)$. En un intento por identificar estos contenedores, se toma de cada contenedor una muestra X_1, X_2de tamaño 2 (que representa el peso de dos paquetes de café). Con base en el resultado del vector estocástico(X_1, X_2) ,se formula una conjetura sobre la distribución de la población, es decir, si se trata de una distribución $N(500, 50)$ o de una distribución $N(490.50)$.

$$
\begin{aligned}
H_0 : \quad & \mu = 500, \quad \sigma^2 = 50, \\
H_1 : \quad & \mu = 490, \quad \sigma^2 = 50.
\end{aligned}
$$

REGIÓN CRÍTICA

- RR: Si ambos X_1 y X_2 son menores o iguales a 496, entonces H_1 se acepta.

$$G = \{(x_1, x_2): x_1, x_2 \leq 494\}$$

- ¿Cuál es el valor de α y β?

DEFINICIONES

- Una prueba de hipótesis se entiende como la siguiente tupla:

$$(X_1, \ldots, X_n; H_0, H_1; G),$$

donde $X_1, \ldots, X_n$ es una muestra, H_0 y H_1son hipótesis acerca de la distribución de probabilidad de la población, y $G \subset \mathbb{R}^n$.

- Supongamos que H_0es una hipótesis estadística simple. El **nivel de significancia** de la prueba de hipótesis $(X_1, \ldots, X_n, H_0, H_1, G)$se entiende como el número

$$\alpha := \mathbb{P}^{H_0}_{X_1,\ldots,X_n}(G).$$

- Esto también se expresa diciendo que la **región crítica** es de tamaño α.

$$\beta = \mathbb{P}^{H_1}_{X_1,\ldots,X_n}(G^c),$$

LEMA DE NEYMAN–PEARSON

Supóngase que la hipótesis $H_0: \theta = \theta_0$ se contrasta frente a $H_1: \theta = \theta_1$ .Sea G la región crítica definida por

$$G = G(\delta) := \left\{ x \in \mathbb{R}^n : \frac{L_0(x)}{L_1(x)} < \delta \right\} \quad (\delta > 0)$$

y sea αsu tamaño. Entonces, entre todas las regiones críticas de tamaño α, esta región crítica Ges la que proporciona la máxima potencia para la prueba.

EN EL EJEMPLO

$H_0 : \mu = 500$ frente a $H_1 : \mu = 490.$

$$L_0(x_1, x_2) = \frac{1}{100\pi} e^{-(x_1-500)^2/100} e^{-(x_2-500)^2/100},$$
$$L_1(x_1, x_2) = \frac{1}{100\pi} e^{-(x_1-490)^2/100} e^{-(x_2-490)^2/100}.$$

$$\frac{L_0(x_1, x_2)}{L_1(x_1, x_2)} = e^{0.2x_1+0.2x_2-198}.$$

$$G(\delta) = \left\{(x_1, x_2) \in \mathbb{R}^2 : \frac{L_0(x_1, x_2)}{L_1(x_1, x_2)} \leq \delta\right\} = \left\{(x_1, x_2) \in \mathbb{R}^2 : x_1 + x_2 \leq g\right\},$$

$$H_0 \ : \ \theta \in \Theta_0 \qquad\qquad H_1 \ : \ \theta \in \Theta_1$$

El **cociente de verosimilitudes (likelihood ratio)**, en el caso de hipótesis compuestas, se define como

$$\Lambda(x_1, \ldots, x_n) := \frac{\sup_{\theta \subset \Theta_0} L_\theta(x_1, \ldots, x_n)}{\sup_{\theta \subset \Theta} L_\theta(x_1, \ldots, x_n)}.$$

El cociente de verosimilitudes $\Lambda(x_1, \ldots, x_n)$ existe para todos los elementos $(x_1, \ldots, x_n)$ en el conjunto

$$D_\Lambda = \left\{ (x_1, \ldots, x_n) \in \mathbb{R}^n : \sup_{\theta \subset \Theta} L_\theta(x_1, \ldots, x_n) \neq 0 \right\}.$$

A este conjunto se le llama **el dominio de Λ.**

$$G(\delta) := \{(x_1, \ldots, x_n) \in D_\Lambda \ : \ \Lambda(x_1, \ldots, x_n) \leq \delta\}.$$

EJEMPLO: $H_0 : \mu = 500$ $H_1 : \mu \neq 500.$

$$L_0(x_1, x_2) = \frac{1}{100\pi} e^{-(x_1-500)^2/100} e^{-(x_2-500)^2/100}$$

$$L_\mu(x_1, x_2) = \frac{1}{100\pi} e^{-(x_1-\mu)^2/100} e^{-(x_2-\mu)^2/100}.$$

$$\Lambda(x_1, x_2) = \frac{e^{-(x_1-500)^2/100}\, e^{-(x_2-500)^2/100}}{e^{-(x_1-\overline{x})^2/100}\, e^{-(x_2-\overline{x})^2/100}}.$$

$$\Lambda(x_1, x_2) = e^{-0.02\left((\overline{x})^2-1000\,\overline{x}+250000\right)} = e^{-0.02(\overline{x}-500)^2}.$$

PRUEBA Z:

Pruebas de hipótesis de nivel α para muestras grandes

$$H_0 : \theta = \theta_0.$$

$$H_a : \begin{cases} \theta > \theta_0 & \text{(alternativa de cola superior).} \\ \theta < \theta_0 & \text{(alternativa de cola inferior).} \\ \theta \neq \theta_0 & \text{(alternativa de dos colas).} \end{cases}$$

Estadístico de prueba: $Z = \dfrac{\hat{\theta} - \theta_0}{\sigma_{\hat{\theta}}}$.

$$\text{Región de rechazo:} \quad \begin{cases} \{z > z_\alpha\} & \text{(RR de cola superior)} \\ \{z < -z_\alpha\} & \text{(RR de cola inferior).} \\ \{|z| > z_{\alpha/2}\} & \text{(RR de dos colas).} \end{cases}$$

EJEMPLO

- El vicepresidente de ventas de una gran empresa afirma que los vendedores están promediando no mas de 15 contactos de venta por semana. (Le gustaría aumentar esta cantidad.) Como prueba de su afirmación, aleatoriamente se seleccionan n = 36 vendedores y se registra el número de contactos hechos por cada uno para una sola semana seleccionada al azar. La media y varianza de las 36 mediciones fueron 17 y 9, respectivamente. ¿La evidencia contradice lo dicho por el vicepresidente? Use una prueba con nivel $\alpha = 0.05$.

$$H_0 : \mu = 15 \quad \text{contra} \quad H_a : \mu > 15.$$

Suposiciones: $Y_1, Y_2, \ldots, Y_n$ constituyen una muestra aleatoria de una distribución normal con $E(Y_i) = \mu$.

$H_0 : \mu = \mu_0$.

$$H_a : \begin{cases} \mu > \mu_0 & \text{(alternativa de cola superior).} \\ \mu < \mu_0 & \text{(alternativa de cola inferior).} \\ \mu \neq \mu_0 & \text{(alternativa de dos colas).} \end{cases}$$

Estadístico de prueba: $T = \dfrac{\overline{Y} - \mu_0}{S/\sqrt{n}}$.

$$\text{Región de rechazo:} \quad \begin{cases} t > t_\alpha & \text{(RR de cola superior).} \\ t < -t_\alpha & \text{(RR de cola inferior).} \\ |t| > t_{\alpha/2} & \text{(RR de dos colas).} \end{cases}$$

EJERCICIO: PYTHON

- Un investigador desea analizar si los pasajeros de primera clase del Titanic eran, en promedio, más jóvenes que el total de pasajeros del barco. Para ello, se cuenta con la base de datos titanic disponible en la biblioteca seaborn de Python, que contiene, entre otras variables, la edad (age) y la clase del pasajero (pclass). Se sabe que la media general de edad de todos los pasajeros es μ_{total} ,y se desea contrastar si la media de edad de los pasajeros de primera clase $\mu_{primera}$ es menor que dicha media poblacional. (Agregar gráficos de la región crítica)

Pruebas de hipótesis referentes a una varianza poblacional

Supuestos: $Y_1, Y_2, \ldots, Y_n$ constituyen una muestra aleatoria de una distribución normal con

$$E(Y_i) = \mu \text{ y } V(Y_i) = \sigma^2.$$

$H_0 : \sigma^2 = \sigma_0^2$

$$H_a : \begin{cases} \sigma^2 > \sigma_0^2 & \text{(alternativa de cola superior).} \\ \sigma^2 < \sigma_0^2 & \text{(alternativa de cola inferior).} \\ \sigma^2 \neq \sigma_0^2 & \text{(alternativa de dos colas).} \end{cases}$$

Estadístico de prueba: $\chi^2 = \dfrac{(n-1)S^2}{\sigma_0^2}$.

$$\text{Región de rechazo:} \quad \begin{cases} \chi^2 > \chi^2_{\alpha} & \text{(RR de cola superior).} \\ \chi^2 < \chi^2_{1-\alpha} & \text{(RR de cola inferior)} \\ \chi^2 > \chi^2_{\alpha/2} \text{ o } \chi^2 < \chi^2_{1-\alpha/2} & \text{(RR de dos colas).} \end{cases}$$

EJERCICIO PYTHON

- Un restaurante desea verificar si la variabilidad de las cuentas totales (total_bill) ha disminuido respecto a su valor histórico. A partir de registros anteriores, se sabe que la desviación estándar histórica de las cuentas era de 8 dólares, lo que corresponde a una varianza poblacional histórica de $\sigma_0^2 = 64$. Con una muestra reciente de cuentas obtenida en el conjunto de datos tips (disponible en seaborn), se busca comprobar si actualmente la varianza es menor que la histórica.

TAREA

- Investigar como llevar a cabo la prueba de hipótesis para cociente de varianzas y diferencia de medias, entre dos poblaciones. Aplicarlo en dos ejemplos propuestos, análogos a los anteriores.

TAMAÑO DE MUESTRA

$$\alpha = P(\overline{Y} > k \text{ cuando } \mu = \mu_0)$$
$$= P\left(\frac{\overline{Y} - \mu_0}{\sigma/\sqrt{n}} > \frac{k - \mu_0}{\sigma/\sqrt{n}} \text{ cuando } \mu = \mu_0\right) = P(Z > z_\alpha),$$
$$\beta = P(\overline{Y} \leq k \text{ cuando } \mu = \mu_a)$$
$$= P\left(\frac{\overline{Y} - \mu_a}{\sigma/\sqrt{n}} \leq \frac{k - \mu_a}{\sigma/\sqrt{n}} \text{ cuando } \mu = \mu_a\right) = P(Z \leq -z_\beta).$$

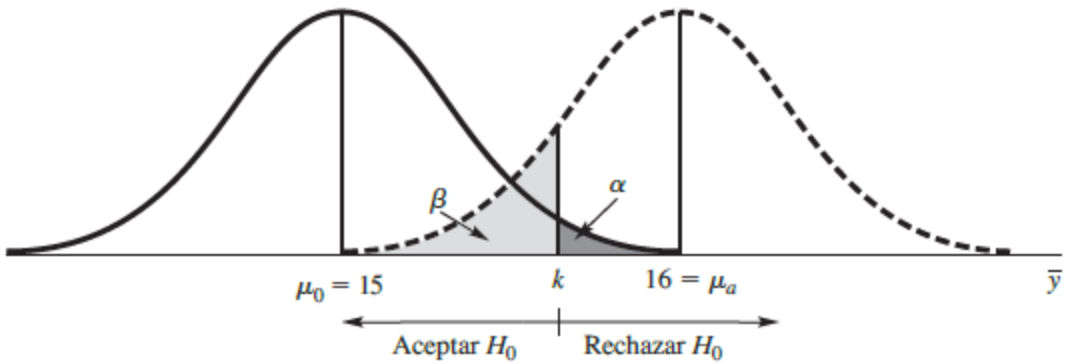

TAMAÑO DE MUESTRA

Tamaño muestral para una prueba de cola superior de nivel α

$$n = \frac{(z_\alpha + z_\beta)^2 \sigma^2}{(\mu_a - \mu_0)^2}$$

TAREA

- Realizar el cálculo análogo para una prueba bilateral (para prueba t).
- Realizar el cálculo análogo para una prueba bilateral (para prueba chi2).
- Elaborar las funciones en Python.

P-VALOR

Si W es un estadístico de prueba, el *valor p*, o *nivel de significancia alcanzado*, es el nivel más pequeño de significancia α para el cual la información observada indica que la hipótesis nula debe ser rechazada.

- El p-value es una medida estadística que cuantifica cuán probables son los datos observados con la propuesta de la hipótesis nula.

- cierta tendencia a ser significativos (p = 0,08)
- cercanos al límite de significancia (p = 0,07)
- al borde de la significancia estadística (p < 0,07)
- muy cerca de ser estadísticamente significativos (p = 0,055)
- rozaron la significancia estadística (p = 0.12)
- no alcanzaron el nivel de significancia por muy poco (p = 0,086)
- significancia casi marginal (p = 0,18)
- solo ligeramente no significativos (p = 0,0738)
- tentativamente significativos (p = 0,073)

P-VALOR

Comparación	Interpretación	Decisión sobre H_0
$p - value < \alpha$	Hay evidencia suficiente para apoyar la hipótesis alternativa.	Se rechaza H_0
$p - value \geq \alpha$	Los datos no contradicen la hipótesis nula.	No se rechaza H_0

¿COMO CALCULARLO?

P-VALUE

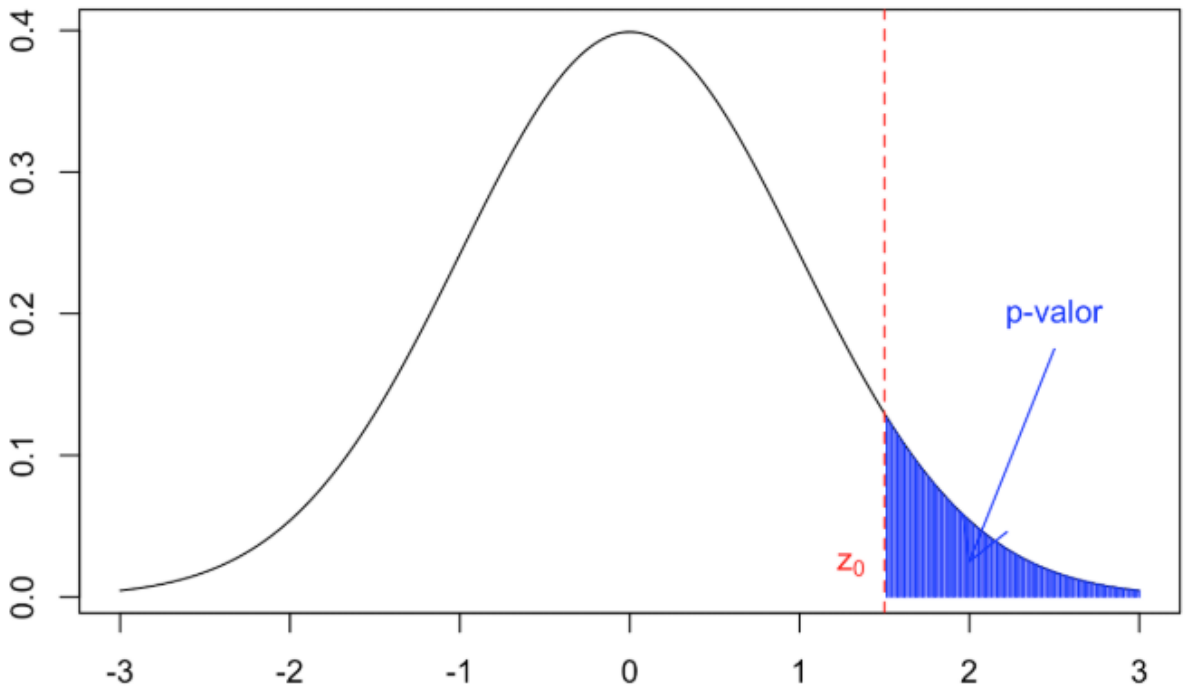

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0. \end{cases}$$

$$p\text{-valor} = P(Z \geq z_0).$$

P-VALUE

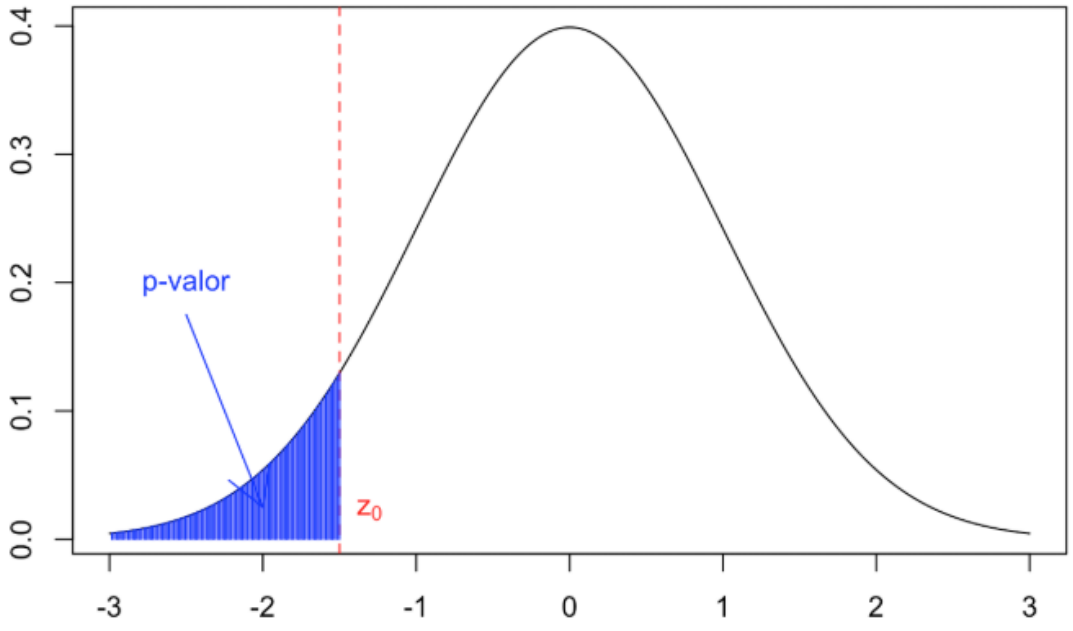

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu < \mu_0. \end{cases}$$

$$p\text{-valor} = P(Z \leq z_0).$$

P-VALUE

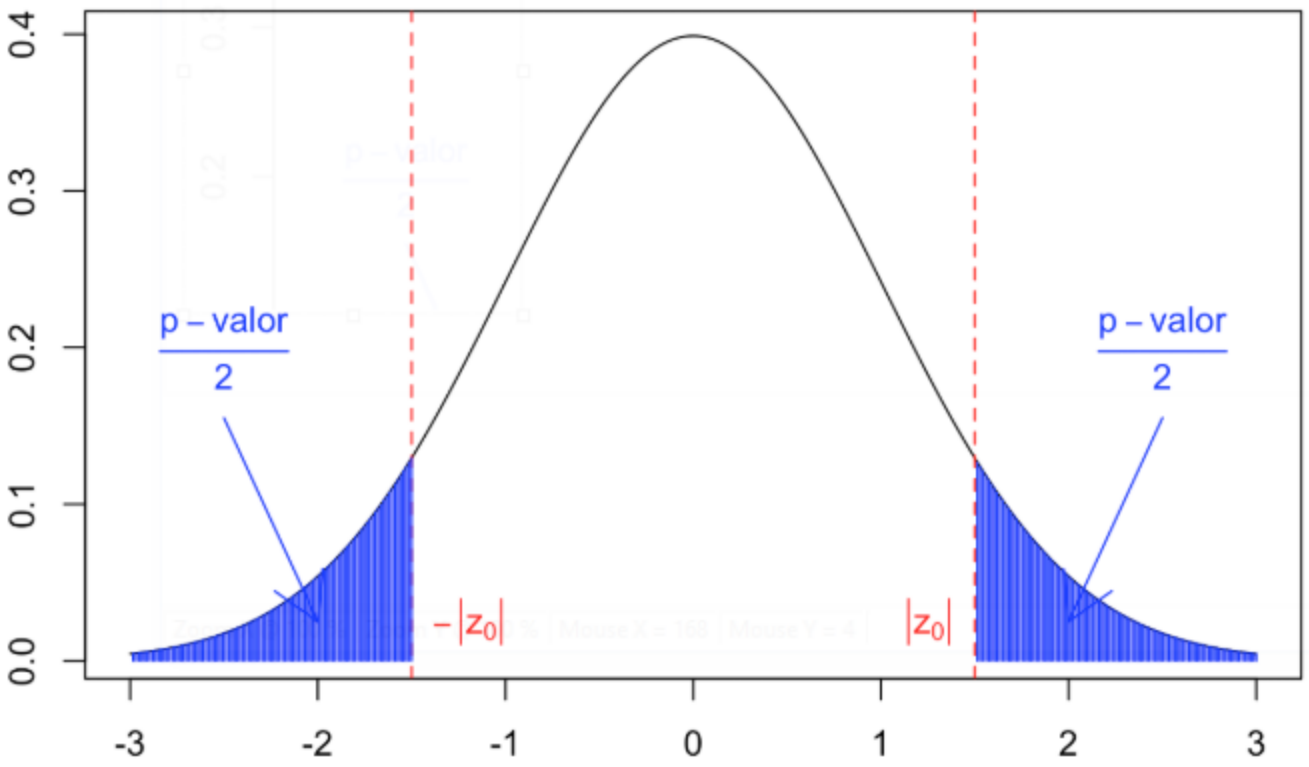

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu \neq \mu_0 \end{cases}$$

$$p\text{-valor} = 2 \cdot P(Z \geq |z_0|)$$

EJEMPLO

- Se realizo un estudio psicológico para comparar los tiempos de reacción de hombres y mujeres a un estimulo. En el experimento se emplearon muestras aleatorias independientes de 50 hombres y 50 mujeres. Los resultados se muestran en la Tabla. ¿Los datos presentan evidencia para sugerir una diferencia entre los tiempos medios de reacción verdaderos para hombres y mujeres? Use $\alpha = 0.05$.

Hombres	Mujeres
$n_1 = 50$	$n_2 = 50$
$\bar{y}_1 = 3.6$ segundos	$\bar{y}_2 = 3.8$ segundos
$s_1^2 = .18$	$s_2^2 = .14$